



دانشکده‌گان علوم و فناوری‌های میان‌رشته‌ای

دانشکده سامانه‌های هوشمند

گروه علوم و فناوری داده

درس کاربرد سیستم‌های هوشمند در پزشکی

استاد: دکتر مهدی تیموری

گردآورنده: مهدیس باقری دورفرد

INDEX

IMPORTS	3
DATA PREPERATION	3
NAIVE BAYES	4
EVALUATION METRICS	7
CROSS VALIDATION.	8
FEATURE ANALYSIS	11
ANALYSIS AND RESULTS	14
CONCLUSION	15

IMPORTS

```
from scipy.io import loadmat
import numpy as np
import pandas as pd
```

DATA PREPERATION

```
mat = loadmat('vote.mat')
```

این خط فایل vote.mat را خوانده و محتویات آن را در متغیر mat بارگذاری می کند.

```
Data = mat['Data']
```

این بخش، متغیری به نام 'Data' را از دیکشنری mat استخراج کرده و در متغیر جدیدی با نام Data ذخیره می کند.

```
feature_names = [
    "HANDICAPPED_INFANTS",
    "WATER_PROJECT_COST_SHARING",
    ...,
    "CRIME",
    "DUTY_FREE_EXPORTS",
    "EXPORT_ADMINISTRATION_ACT_SOUTH_AFRICA"
]
```

این قسمت یک لیست از نام ویژگی ها را تعریف می کند که ستون های دیتاست را توصیف می کنند. این دیتاست مربوط به رأی گیری اعضای کنگره آمریکا¹ است که در آن هر ستون نشان دهنده رأی نمایندگان درباره یک موضوع سیاسی خاص است.

```
X = Data[:, :16]
y = Data[:, 16]
```

تمام ویژگی ها از دیتاست استخراج میشوند و در متغیر X ذخیره میشوند. ستون آخر دیتا یا همان لیبل ها نیز استخراج شده و در y ذخیره میشوند.

¹ Congressional Voting Records Dataset

Train_naive_bayes تابع

این تابع مرحله آموزش یک مدل Naive Bayes برنولی^۲ را انجام می‌دهد.

```
def train_naive_bayes(X_train, y_train):
```

ورودی‌ها: ماتریس ویژگی‌ها و برچسب کلاس‌ها

```
p_democrat = np.mean(y_train == 1)
p_republican = np.mean(y_train == 0)
```

احتمال پیشین دو کلاس محاسبه می‌شود. یعنی نسبت نمونه‌های دموکرات ($y=1$) و جمهوری‌خواه ($y=0$) در مجموعه آموزشی را به دست می‌آورد

```
alpha = (
    np.sum(X_train[y_train == 1], axis=0) + 1
) / (
    np.sum(y_train == 1) + 2)
```

این خط مهم‌ترین بخش آموزش Naive Bayes است و احتمال شرطی هر ویژگی را برای کلاس دموکرات محاسبه می‌کند. در این دستور ابتدا تمام نمونه‌هایی که برچسب آن‌ها برابر ۱ (دموکرات) است انتخاب می‌شوند. سپس با استفاده از `np.sum(..., axis=0)` تعداد دفعاتی که هر ویژگی در میان دموکرات‌ها مقدار ۱ داشته است، برای هر ستون به صورت جداگانه محاسبه می‌شود. پس از آن، برای جلوگیری از صفر شدن احتمال‌ها، یک واحد به صورت کسر اضافه می‌شود که به این روش هموارسازی لاپلاس^۳ گفته می‌شود. در مخرج نیز تعداد کل نمونه‌های دموکرات محاسبه شده و عدد ۲ به آن افزوده می‌شود؛ زیرا هر ویژگی یک متغیر دودویی با دو حالت ممکن (۰ و ۱) است. در نتیجه، هر عنصر از بردار `alpha` بیانگر احتمال مشاهده مقدار ۱ برای یک ویژگی خاص به شرط دموکرات بودن فرد است. به بیان دیگر، `alpha` مجموعه‌ای از احتمال‌های $P(X_j=1|Democrat)$ را برای تمام ویژگی‌ها در اختیار مدل قرار می‌دهد تا در مرحله پیش‌بینی بتواند احتمال تعلق یک نمونه جدید به کلاس دموکرات را محاسبه کند.

```
beta = (
    np.sum(X_train[y_train == 0], axis=0) + 1
) / (
    np.sum(y_train == 0) + 2)
```

این خط در واقع احتمال شرطی ویژگی‌ها برای کلاس جمهوری‌خواه ($y=0$) را با هموارسازی لاپلاس محاسبه می‌کند؛ یعنی تعداد دفعات حضور هر ویژگی در بین جمهوری‌خواهان را می‌شمارد، یک واحد به آن اضافه می‌کند و بر تعداد کل جمهوری‌خواهان (به علاوه ۲ برای حالت‌های دودویی) تقسیم می‌کند تا احتمال پایدار و بدون صفر شدن به دست آید.

```
return p_democrat, p_republican, alpha, beta
```

^۲ Bernoulli Naive Bayes

^۳ Laplace Smoothing

در نهایت تابع چهار پارامتر اصلی مدل یعنی احتمال پیشین دموکرات ها (p_{democrat})، احتمال پیشین جمهوری خواهان ($p_{\text{republican}}$) و دو بردار احتمال شرطی α و β را بازمی گرداند تا در مرحله پیش بینی برای محاسبه احتمال تعلق نمونه های جدید به هر کلاس استفاده شوند.

تایم Predication

در این تابع، مدل Naive Bayes آموزش داده شده برای پیش بینی کلاس نمونه های تست استفاده می شود و خروجی آن لیستی از برچسب های پیش بینی شده (دموکرات یا جمهوری خواه) است.

```
def predict_naive_bayes(X_test, p_democrat, p_republican, alpha, beta):
```

این تابع داده های تست (X_{test}) را همراه با پارامترهای آموزش دیده مدل دریافت می کند:

- p_{democrat} و $p_{\text{republican}}$: احتمال پیشین هر کلاس
- α : احتمال ویژگی ها در کلاس دموکرات
- β : احتمال ویژگی ها در کلاس جمهوری خواه

```
predictions = []
```

یک لیست خالی ساخته می شود تا پیش بینی هر نمونه در آن ذخیره شود.

```
for x in X_test:
```

هر سطر X یک نمونه (یک رأی دهنده) است و به صورت جداگانه بررسی می شود.

```
log_democrat = np.log(p_democrat)
log_republican = np.log(p_republican)
```

اینجا احتمال های پیشین به لگاریتم تبدیل می شوند تا:

- از ضرب های خیلی کوچک جلوگیری شود
- محاسبات پایدارتر شوند

```
log_democrat += np.sum(
    x * np.log(alpha)
    + (1 - x) * np.log(1 - alpha)
)
```

در این قسمت:

- اگر $x=1$ باشد از $\log(\alpha)$ استفاده می شود
- اگر $x=0$ باشد از $\log(1 - \alpha)$ استفاده می شود

یعنی مدل بررسی می کند هر ویژگی چقدر با کلاس دموکرات سازگار است. بعد همه ویژگی ها با هم جمع می شوند (فرض استقلال Naive Bayes)

```
log_republican += np.sum(
    x * np.log(beta)
    + (1 - x) * np.log(1 - beta)
)
```

همین محاسبه برای کلاس جمهوری خواه انجام می شود، فقط با پارامترهای beta

```
if log_democrat >= log_republican:
    predictions.append(1)
else:
    predictions.append(0)
```

- اگر احتمال دموکرات بودن بیشتر باشد: برچسب ۱
- اگر کمتر باشد: برچسب ۰

در واقع مدل تصمیم می گیرد هر نمونه متعلق به کدام کلاس است.

```
return np.array(predictions)
```

لیست پیش بینی ها به آرایه NumPy تبدیل و برگردانده می شود.

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

```
def confusion_matrix_binary(y_true, y_pred):
```

```
    TP = np.sum((y_true == 1) & (y_pred == 1))
    TN = np.sum((y_true == 0) & (y_pred == 0))
    FP = np.sum((y_true == 0) & (y_pred == 1))
    FN = np.sum((y_true == 1) & (y_pred == 0))
```

```
    return TP, TN, FP, FN
```

این تابع یک ماتریس درهم‌ریختگی⁴ برای مسئله‌ی دودویی می‌سازد و با مقایسه‌ی y_{true} (برچسب واقعی) و y_{pred} (برچسب پیش‌بینی‌شده)، تعداد درست‌ها و خطاهای مدل را در چهار دسته‌ی TP، FN، FP و TN محاسبه می‌کند؛ یعنی تعداد پیش‌بینی‌های درست برای کلاس ۱ (TP)، درست برای کلاس ۰ (TN)، پیش‌بینی اشتباه ۱ به جای ۰ (FP) و پیش‌بینی اشتباه ۰ به جای ۱ (FN) را جداگانه شمارش کرده و برمی‌گرداند.

⁴ Confusion Matrix

🚩 تابع 5_Fold Cross Validation

این بخش یک پیاده‌سازی کامل از اعتبارسنجی متقاطع ۵ بخشی^۵ برای مدل Naive Bayes است که هم آموزش مدل را انجام می‌دهد، هم پیش‌بینی، و هم عملکرد آن را با معیارهای مختلف ارزیابی می‌کند.

```
fold_size = 65
```

یعنی داده‌ها طوری تقسیم می‌شوند که هر بخش تست شامل 65 نمونه باشد.

```
errors = []
accuracies = []
precisions = []
recalls = []
```

این لیست‌ها برای ذخیره نتایج هر fold استفاده می‌شوند:

- errors: نرخ خطا
- accuracies: دقت
- precisions: دقت مثبت‌ها
- recalls: حساسیت

```
for fold in range(5):
```

یعنی مدل ۵ بار آموزش و تست می‌شود. (5-Fold)

```
start = fold * fold_size
end = start + fold_size
```

برای هر fold مشخص می‌کند کدام بخش از داده تست باشد.

```
X_test = X[start:end]
y_test = y[start:end]
```

این بخش از داده جدا می‌شود و فقط برای تست استفاده می‌شود

```
X_train = np.concatenate(
    [X[:start], X[end:]],
    axis=0)
```

ساخت داده آموزش: قبل از بخش تست + بعد از بخش تست

```
y_train = np.concatenate(
```

^۵ 5-Fold Cross Validation


```
[y[:start], y[end:]])
```

همین کار برای برچسب‌ها انجام می‌شود.

```
p_democrat, p_republican, alpha, beta = \
    train_naive_bayes(X_train, y_train)
```

در این بخش آموزش مدل Naive Bayes انجام میشود. مدل روی داده آموزش یاد می‌گیرد:

- احتمال دموکرات بودن
- احتمال جمهوری‌خواه بودن
- احتمال ویژگی‌ها در هر کلاس

```
y_pred = predict_naive_bayes(
    X_test,
    p_democrat,
    p_republican,
    alpha,
    beta)
```

مدل برای هر نمونه تست تصمیم می‌گیرد 1دموکرات و ۰ جمهوری‌خواه

```
TP, TN, FP, FN = \
    confusion_matrix_binary(y_test, y_pred)
```

محاسبه Confusion Matrix. چهار حالت بررسی می‌شود:

- TP درست دموکرات
- TN درست جمهوری‌خواه
- FP اشتباه دموکرات
- FN اشتباه جمهوری‌خواه

```
accuracy = (TP + TN) / len(y_test)
```

در این بخش Accuracy محاسبه میشود. یعنی چند تا از پیش‌بینی‌ها درست بوده‌اند؟

```
error = 1 - accuracy
```

محاسبه Error یعنی درصد خطا.

```
precision = TP / (TP + FP) \
```

```
if (TP + FP) > 0 else 0
```

محاسبه Precision یعنی: از چیزهایی که گفتیم "دموکرات"، چندتاش واقعاً دموکرات بود؟

```
recall = TP / (TP + FN) \
    if (TP + FN) > 0 else 0
```

محاسبه Recall یعنی از همه دموکرات‌های واقعی، چندتاش درست تشخیص داده شد؟

```
accuracies.append(accuracy)
errors.append(error)
precisions.append(precision)
recalls.append(recall)
```

نتایج هر fold ذخیره می‌شود تا بعداً میانگین بگیریم.

Overall Cross Validation Result 📊

```
for i in range(5):

    print(
        f"Fold {i+1}: "
        f"Accuracy={accuracies[i]*100:.2f}% , "
        f"Error={errors[i]*100:.2f}%"
    )

print("\nAverage Results")
```

این بخش کد نتایج نهایی اعتبارسنجی متقاطع⁶ را نمایش می‌دهد؛ ابتدا یک عنوان کلی چاپ می‌شود، سپس برای هر یک از ۵ fold مقدار دقت و خطا همان fold از لیست‌های ذخیره‌شده accuracies و errors خوانده شده و نمایش داده می‌شود. در ادامه، برای جمع‌بندی عملکرد مدل، میانگین معیارها روی تمام fold ها با استفاده از np.mean محاسبه می‌شود و شامل میانگین دقت، خطا، Precision و Recall است. این بخش در واقع یک دید کلی از عملکرد نهایی مدل روی کل داده‌ها ارائه می‌دهد تا مشخص شود مدل در حالت میانگین چقدر دقیق و پایدار عمل کرده است.

⁶ Cross Validation

Train On Full Dataset for Feature Analysis 🚦

این کد:

۱. مدل Naive Bayes را آموزش می دهد
۲. برای هر ویژگی یک وزن تفکیک کننده کلاس ها حساب می کند
۳. بررسی می کند هر ویژگی بیشتر به کدام حزب گرایش دارد
۴. در نهایت یک لیست می سازد که نشان می دهد

```
p_democrat, p_republican, alpha, beta = \
    train_naive_bayes(X, y)
```

این خط مدل Naive Bayes را روی کل داده آموزش می دهد و چهار پارامتر اصلی را برمی گرداند:

- p_democrat: احتمال پیشین دموکرات ها $P(D)$
- p_republican: احتمال پیشین جمهوری خواهان $P(R)$
- alpha: احتمال هر ویژگی در کلاس دموکرات $P(X|D)$
- beta: احتمال هر ویژگی در کلاس جمهوری خواه $P(X|R)$

```
weights = (
    np.log(alpha / (1 - alpha))
    -
    np.log(beta / (1 - beta)))
```

بخش اول این قسمت برای هر ویژگی حساب می کند:

$$\log \left(\frac{P(X = 1 | Democrat)}{P(X = 0 | Democrat)} \right)$$

یعنی:

این ویژگی چقدر در دموکرات ها "قوی تر" است

بخش دوم:

همین محاسبه برای جمهوری خواهان:

$$\log \left(\frac{P(X = 1 | Republican)}{P(X = 0 | Republican)} \right)$$

سپس از هم کم میشوند. یعنی

$$weight = \log_odds(Democrat) - \log_odds(Republican)$$

نتیجه مهم:

- اگر $weight > 0$ ویژگی به نفع دموکرات‌هاست
- اگر $weight < 0$ ویژگی به نفع جمهوری‌خواهان است
- اگر $weight = 0$ بی‌اثر است

```
tendency = []
```

یک لیست خالی ساخته می‌شود تا نتیجه هر ویژگی داخل آن ذخیره شود.

```
for w in weights:
```

برای تک‌تک ویژگی‌ها (مثلاً ۱۶ ویژگی) حلقه اجرا می‌شود

```
if w > 0:
    tendency.append("Democrat")
```

اگر وزن مثبت باشد، این ویژگی بیشتر در دموکرات‌ها دیده شده

```
elif w < 0:
    tendency.append("Republican")
```

اگر وزن منفی باشد: این ویژگی بیشتر در جمهوری‌خواهان دیده شده

```
else:
    tendency.append("Neutral")
```

اگر وزن دقیقاً صفر باشد: ویژگی در هر دو کلاس به یک اندازه مهم است

```
feature_table = pd.DataFrame({
    "Feature": feature_names,
    "Alpha=P(x=1|Democrat)": alpha,
    "Beta=P(x=1|Republican)": beta,
    "Weight": weights,
    "AbsWeight": np.abs(weights),
    "Tendency": tendency})
```

این کد یک DataFrame تحلیلی کامل می‌سازد که برای هر ویژگی در مدل Naive Bayes، اطلاعات آماری و تفسیر سیاسی آن را کنار هم قرار می‌دهد.

در این کد از `pd.DataFrame` استفاده شده تا یک ساختار جدولی ایجاد شود که شامل نام هر ویژگی (Feature)، احتمال حضور آن در کلاس دموکرات‌ها ($\text{Alpha} = P(x=1 | \text{Democrat})$)، احتمال حضور آن در کلاس جمهوری‌خواهان ($\text{Beta} = P(x=1 | \text{Republican})$)، وزن تفکیک‌کننده بین دو کلاس (Weight) که نشان می‌دهد هر ویژگی به نفع کدام حزب است، مقدار قدرمطلق وزن (AbsWeight) که شدت اهمیت ویژگی را بدون توجه به جهت نشان می‌دهد، و در نهایت ستون Tendency که نتیجه نهایی تفسیر را به صورت متنی Democrat، Republican یا Neutral مشخص می‌کند، تشکیل شده است. در واقع این جدول کمک می‌کند تا به جای دیدن اعداد خام مدل، بتوانیم به صورت قابل فهم ببینیم هر ویژگی چقدر مهم است و به کدام سمت سیاسی گرایش دارد.

=====						
FEATURE ANALYSIS (ORIGINAL ORDER)						
=====						
Feature	Alpha=P(x=1 Democrat)	Beta=P(x=1 Republican)	Weight	AbsWeight	Tendency	
HANDICAPPED_INFANTS	0.591549	0.275862	1.335455	1.335455	Democrat	
WATER_PROJECT_COST_SHARING	0.535211	0.560345	-0.101483	0.101483	Republican	
ADOPTION_OF_BUDGET_RESOLUTION	0.863850	0.198276	3.244745	3.244745	Democrat	
PHYSICIAN_FEE_FREEZE	0.065728	0.974138	-6.283023	6.283023	Republican	
EL_SALVADOR_AID	0.258216	0.922414	-3.530866	3.530866	Republican	
RELIGIOUS_GROUPS_IN_SCHOOLS	0.549296	0.844828	-1.496770	1.496770	Republican	
ANTI_SATELLITE_TEST_BAN	0.723005	0.336207	1.639659	1.639659	Democrat	
AID_TO_NICARAGUAN_CONTRAS	0.788732	0.206897	2.661036	2.661036	Democrat	
MX_MISSILE	0.718310	0.163793	2.566365	2.566365	Democrat	
IMMIGRATION	0.497653	0.560345	-0.251951	0.251951	Republican	
SYNFUELS_CORPORATION_CUTBACK	0.521127	0.155172	1.779153	1.779153	Democrat	
EDUCATION_SPENDING	0.173709	0.827586	-3.128182	3.128182	Republican	
SUPERFUND_RIGHT_TO_SUE	0.328638	0.827586	-2.282965	2.282965	Republican	
CRIME	0.408451	0.965517	-3.702578	3.702578	Republican	
DUTY_FREE_EXPORTS	0.610329	0.129310	2.355764	2.355764	Democrat	
EXPORT_ADMINISTRATION_ACT_SOUTH_AFRICA	0.849765	0.715517	0.810428	0.810428	Democrat	

نتایج تحلیل ویژگی‌ها بر اساس مدل Naive Bayes نشان می‌دهد که هر یک از مسائل سیاسی موجود در دیتاست نقش متفاوتی در تفکیک میان دو حزب دموکرات و جمهوریخواه دارند. مقادیر Alpha و Beta احتمال رأی موافق (۱) را به ترتیب در میان اعضای دموکرات و جمهوریخواه نشان می‌دهند و اختلاف میان آن‌ها بیانگر میزان تمایز هر ویژگی بین دو کلاس است. بر این اساس، برخی موضوعات مانند «ADOPTION_OF_BUDGET_RESOLUTION»، «AID_TO_NICARAGUAN_CONTRAS» و «MX_MISSILE» دارای مقادیر بالاتر در دموکرات‌ها بوده و به عنوان شاخص‌های قوی برای این حزب شناسایی شده‌اند، در حالی که موضوعاتی نظیر «PHYSICIAN_FEE_FREEZE»، «CRIME» و «EL_SALVADOR_AID» با احتمال بسیار بالاتر در جمهوریخواهان مشاهده شده و به طور معناداری در جهت این حزب تمایل دارند. ستون Weight که بر اساس اختلاف لگاریتمی احتمال‌ها محاسبه شده است، شدت و جهت اثر هر ویژگی را در تفکیک کلاس‌ها نشان می‌دهد؛ به گونه‌ای که مقادیر بزرگ مثبت یا منفی بیانگر نقش قوی آن ویژگی در تصمیم‌گیری مدل هستند. به طور کلی، ویژگی‌هایی با مقدار قدرمطلق وزن بالاتر، مانند «PHYSICIAN_FEE_FREEZE» و «CRIME»، بیشترین قدرت تفکیک را داشته و نقش تعیین‌کننده‌تری در طبقه‌بندی ایفا می‌کنند. ستون Tendency نیز تفسیر کیفی این روابط را ارائه داده و نشان می‌دهد هر ویژگی در نهایت به کدام حزب گرایش دارد. در مجموع، این نتایج بیانگر آن است که مدل Naive Bayes قادر است الگوهای سیاسی معناداری را از داده‌های رأی‌گیری استخراج کرده و تفاوت‌های ساختاری میان رفتار رأی‌دهی دو حزب را به صورت کمی و قابل تفسیر مدل‌سازی کند.

TOP 5 MOST IMPORTANT FEATURES

Feature	Weight	Tendency
PHYSICIAN_FEE_FREEZE	-6.283023	Republican
CRIME	-3.702578	Republican
EL_SALVADOR_AID	-3.530866	Republican
ADOPTION_OF_BUDGET_RESOLUTION	3.244745	Democrat
EDUCATION_SPENDING	-3.128182	Republican

نتایج بخش «Top 5 Most Important Features» نشان می‌دهد که مدل Naive Bayes کدام ویژگی‌های سیاسی را به‌عنوان قوی‌ترین عوامل تفکیک میان دو حزب شناسایی کرده است. این رتبه‌بندی بر اساس مقدار قدرمطلق وزن‌ها انجام شده و بنابراین ویژگی‌هایی انتخاب شده‌اند که بیشترین تأثیر را در تصمیم‌گیری مدل دارند. همان‌طور که مشاهده می‌شود، «PHYSICIAN_FEE_FREEZE» با بیشترین وزن منفی قوی‌ترین شاخص برای جمهوری‌خواهان است و پس از آن موضوعاتی مانند «CRIME» و «EL_SALVADOR_AID» نیز در همین جهت قرار دارند که نشان‌دهنده نقش پررنگ آن‌ها در تشخیص این حزب است. در مقابل، «ADOPTION_OF_BUDGET_RESOLUTION» تنها ویژگی در میان پنج مورد برتر است که وزن مثبت دارد و به‌عنوان شاخص قوی برای دموکرات‌ها عمل می‌کند. همچنین «EDUCATION_SPENDING» نیز با وزن منفی بالا در جهت جمهوری‌خواهان قرار گرفته است. به‌طور کلی این نتایج نشان می‌دهد که چند موضوع کلیدی دارای قدرت تفکیک بسیار بالا هستند و مدل عمدتاً بر اساس همین ویژگی‌های محدود اما معنادار قادر به تمایز میان دو حزب عمل می‌کند.

CONCLUSION

در مجموع، نتایج این پروژه نشان می‌دهد که مدل Naive Bayes با استفاده از داده‌های رأی‌گیری کنگره آمریکا توانسته است به‌صورت مؤثر الگوهای سیاسی پنهان را استخراج کرده و تفاوت‌های معنادار میان دو حزب دموکرات و جمهوری‌خواه را به‌صورت کمی مدل‌سازی کند. تحلیل احتمالات شرطی، وزن ویژگی‌ها و رتبه‌بندی اهمیت آن‌ها نشان می‌دهد که تعداد محدودی از موضوعات سیاسی نقش اصلی را در تفکیک دو کلاس ایفا می‌کنند و همین ویژگی‌های کلیدی مانند سیاست‌های مالی، نظامی و اجتماعی بیشترین قدرت پیش‌بینی را دارند. همچنین نتایج اعتبارسنجی متقاطع نشان می‌دهد که مدل از پایداری و دقت مناسبی برخوردار است و معیارهایی مانند Accuracy، Precision و Recall عملکرد قابل قبولی را در تمام fold ها گزارش می‌کنند. در نتیجه می‌توان گفت Naive Bayes علاوه بر دقت مناسب، تفسیرپذیری بالایی نیز فراهم کرده و امکان تحلیل قابل فهم از رفتار رأی‌دهی نمایندگان و تفاوت ساختاری بین دو حزب را به‌خوبی فراهم می‌سازد.